

# Bayesian Statistics Stuff

贝叶斯公式：

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_j P(A|B_j)P(B_j)} \quad (1)$$

## 1 先验概率 Prior Probability

基于背景常识、或历史数据的统计得出的预判概率。

## 2 条件概率 Conditional Probability

表示一个事件发生后另一个事件发生的概率。

$$P(A|B) = \frac{P(AB)}{P(B)} \quad (2)$$

## 3 后验概率 Posterior Probability

一个随机事件（或一个不确定事件）的后验概率：是在考虑和给出相关数据后所得到的条件概率。

### 3.1 Example:

假设某学校里有：

- 男生： 60 %
- 女生： 40 %
- $\forall$  男生， 穿裤子。
- 50 % 女生， 穿裤子； 另外 50 % 女生， 穿裙子。

问题： 现知道 某学生穿裤子， 问其是女生的概率是多少？

Let

- event A: 看到的是女生
- event B: 看到的是穿裤子的学生

To answer the question, we need to have  $P(A|B)$ , meaning: given 穿裤子的学生 (B), the probability of 看到的是女生 (A).

$$\begin{aligned} P(A) &= 40\% \\ P(B|A) &= 50\% \\ P(B) &= 60\% \times 100\% + 40\% \times 50\% = 80\% \end{aligned} \quad (3)$$

使用贝叶斯定理，求得后验概率：

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \frac{0.5 \times 0.4}{0.8} = 0.25$$

## 4 似然函数 Likelihood Function

关于统计模型中参数的函数，表示模型参数的拟然性。

在已知某参数  $\alpha$  时，事件  $A$  会发生的条件概率为  $P(A; \alpha)$ , same as  $P(A|\alpha)$ . 我们可以用构造拟然性的方法来表示事件  $A$  发生后估计参数  $\alpha$  的可能性，表示为  $L(\alpha|A)$ 。

### 4.1 拟然与概率的区别：

概率用于在已知参数的情况下，预测接下来的观测所得到的结果。

而拟然性则是用于在已知某些观测所得到的结果时，对有关事物的性质的参数进行估计。

### 4.2 似然函数可以理解为条件概率的逆反：

已知参数  $\alpha$ ，事件  $A$  的发生概率：

$$P(A|\alpha) = \frac{P(A, \alpha)}{P(\alpha)}$$

使用 Bayes Rule:

$$P(\alpha|A) = \frac{P(A|\alpha)P(\alpha)}{P(A)}$$

形式上，似然函数也是一种条件概率函数，但我们关注的变量改变了： $L(\alpha|A) = \lambda P(A|\alpha)$

### 4.3 Example:

Todo: give example, or refer to the coin-tossing example given in Wikipedia.

## 5 Review: 最大拟然估计 Maximum Likelihood Estimation (MLE) - Frequentist Statistics

From the point of view of Bayesian Inference, MLE is a special case of maximum a posteriori estimation (MAP) that assumes a uniform prior distribution of the parameters.

模型已定，参数未知。

似然函数取得最大值表示相应的参数能够使得统计模型最为合理。

**前提假设**：最大似然估计中采样需满足一个很重要的假设，就是所有的采样都是独立同分布的。

**Warning**: 最大似然估计只考虑某个模型能产生某个给定观察序列的概率。而未考虑该模型本身的概率。这点与贝叶斯估计区别。

Example:

We have i.i.d. samples  $x_1, x_2, \dots, x_n$ . The assumed model is  $f$  and the parameter for the model is  $\theta$ . Thus we have:

$$f(x_1, x_2, \dots, x_n|\theta) = f(x_1|\theta) \cdot f(x_2|\theta) \cdot f(x_3|\theta) \cdots f(x_n|\theta) = \prod_{i=1}^n f(x_i|\theta)$$

Having  $\log$  on both sides, we have:

$$\ln L(\theta|x_1, x_2, \dots, x_n) = \sum_{i=1}^n \ln f(x_i|\theta)$$

Thus,

$$\hat{\theta}_{mle} = \arg \max L(\theta|x_1, x_2, \dots, x_n)$$

Usually, we apply derivatives to get the maximum value of  $\theta$

For example, if assumed model follows Gaussian Distribution, then: We have Gaussian i.i.d. samples  $x_1, x_2, \dots, x_n$ . Gaussian distribution parameters are  $\mu, \sigma^2$

$$\begin{aligned} L(\mu, \sigma^2|x_1, x_2, \dots, x_n) &= f(x_1|\mu, \sigma^2) \cdot f(x_2|\mu, \sigma^2) \cdots f(x_n|\mu, \sigma^2) \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_1-\mu)^2}{2\sigma^2}} \cdot \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_2-\mu)^2}{2\sigma^2}} \cdots \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_n-\mu)^2}{2\sigma^2}} \\ &= \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left(-\frac{1}{2\sigma^2} \cdot \sum_{i=1}^n (x_i - \mu)^2\right) \\ \frac{d}{d\mu} L(\mu, \sigma^2|x_1, x_2, \dots, x_n) &= 0 \\ \implies \mu &= \frac{x_1 + x_2 + \cdots + x_n}{n} \end{aligned}$$

## 6 最大后验概率 Maximum A Posteriori Estimation

$$\underbrace{P(\theta|X)}_{\text{Posterior Probability}} = \frac{P(X|\theta)P(\theta)}{P(X)}$$

We try to have  $\hat{\theta}$  from  $\arg \max P(\theta|X)$ . The  $P(X|\theta)$  is similar to the one in MLE, as  $P(x_1|\theta) \cdot P(x_2|\theta) \cdots P(x_n|\theta)$ . MAP take prior distribution into consideration, that's  $P(\theta)$ .

Reference: [Maximum a Posteriori Probability Estimation \(MAP\) - Ch2 Estimating Probabilities](#)

## 7 共轭先验 Conjugate Prior