

分类： 机器学习 (45) C/C++编程 (17)

版权声明：本文为博主原创文章，未经博主允许不得转载。 <https://blog.csdn.net/zouxy09/article/details/49105265>

标签传播算法 (Label Propagation) 及Python实现

zouxy09@qq.com

<http://blog.csdn.net/zouxy09>

众所周知，机器学习可以大体分为三大类：监督学习、非监督学习和半监督学习。监督学习可以认为是有非常多的labeled标来train一个模型，期待这个模型能学习到数据的分布，以期对未来没有见到的样本做预测。那这个性能的源头--训练数据，就显得非常你必须有足够的训练数据，以覆盖真正现实数据中的样本分布才可以，这样学习到的模型才有意义。那非监督学习就是没有任何的labeled数据，就是平时所说的聚类了，利用他们本身的数据分布，给他们划分类别。而半监督学习，顾名思义就是处于两者之间的，只有labeled数据，我们试图从这少量的labeled数据和大量的unlabeled数据中学习到有用的信息。


一、半监督学习

半监督学习 (Semi-supervised learning) 发挥作用的场合是：你的数据有一些有label，一些没有。而且一般是绝大部分都没有，许几个有label。半监督学习算法会充分的利用unlabeled数据来捕捉我们整个数据的潜在分布。它基于三大假设：

- 1) Smoothness平滑假设：相似的数据具有相同的label。
- 2) Cluster聚类假设：处于同一个聚类下的数据具有相同label。
- 3) Manifold流形假设：处于同一流形结构下的数据具有相同label。

例如下图，只有两个labeled数据，如果直接用他们来训练一个分类器，例如LR或者SVM，那么学出来的分类面就是左图那样的。现实中，这个数据是右图那边分布的话，猪都看得出来，左图训练的这个分类器烂的一塌糊涂、惨不忍睹。因为我们的labeled训练数据了，都没办法覆盖我们未来可能遇到的情况。但是，如果右图那样，把大量的unlabeled数据（黑色的）都考虑进来，有个全局观念，算法会发现，哎哟，原来是两个圈圈（分别处于两个圆形的流形之上）！那算法就很聪明，把大圈的数据都归类为红色类别，把内圈都归类为蓝色类别。因为，实践中，labeled数据是昂贵，很难获得的，但unlabeled数据就不是了，写个脚本在网上爬就可以了，因此充分利用大量的unlabeled数据来辅助提升我们的模型学习，这个价值就非常大。

Figure 1: Unlabeled Data and Prior Beliefs



半监督学习算法有很多，下面我们介绍最简单的标签传播算法 (label propagation)，最喜欢简单了，哈哈。

二、标签传播算法

标签传播算法 (label propagation) 的核心思想非常简单：相似的数据应该具有相同的label。LP算法包括两大步骤：1) 构造相似2) 勇敢的传播吧。

2.1、相似矩阵构建

LP算法是基于Graph的，因此我们需要先构建一个图。我们为所有的数据构建一个图，图的节点就是一个数据点，包含labeled和unlabeled的数据。节点i和节点j的边表示他们的相似度。这个图的构建方法有很多，这里我们假设这个图是全连接的，节点i和节点j的边权重为：

$$w_{ij} = \exp\left(-\frac{\|x_i - x_j\|^2}{\alpha^2}\right)$$

这里， α 是超参。

还有个非常常用的图构建方法是knn图，也就是只保留每个节点的k近邻权重，其他的为0，也就是不存在边，因此是稀疏的相似矩

2.2、LP算法

标签传播算法非常简单：通过节点之间的边传播label。边的权重越大，表示两个节点越相似，那么label越容易传播过去。我们定义 $N \times N$ 的概率转移矩阵 P ：

$$P_{ij} = P(i \rightarrow j) = \frac{w_{ij}}{\sum_{k=1}^n w_{ik}}$$

P_{ij} 表示从节点 i 转移到节点 j 的概率。假设有 C 个类和 L 个labeled样本，我们定义一个 $L \times C$ 的label矩阵 Y_L ，第 i 行表示第 i 个样本的标签量，即如果第 i 个样本的类别是 j ，那么该行的第 j 个元素为1，其他为0。同样，我们也给 U 个unlabeled样本一个 $U \times C$ 的label矩阵 Y_U 。把并，我们得到一个 $N \times C$ 的soft label矩阵 $F = [Y_L; Y_U]$ 。soft label的意思是，我们保留样本 i 属于每个类别的概率，而不是互斥性的，这个概率1只属于一个类。当然了，最后确定这个样本 i 的类别的时候，是取max也就是概率最大的那个类作为它的类别的。那 F 里面有个 Y_U ，始是不知道的，那最开始的值是多少？无所谓，随便设置一个值就可以了。

千呼万唤始出来，简单的LP算法如下：

- 1) 执行传播： $F = PF$
- 2) 重置 F 中labeled样本的标签： $F_L = Y_L$
- 3) 重复步骤1) 和2) 直到 F 收敛。

步骤1) 就是将矩阵 P 和矩阵 F 相乘，这一步，每个节点都将自己的label以 P 确定的概率传播给其他节点。如果两个节点越相似（在空间中距离越近），那么对方的label就越容易被自己的label赋予，就是更容易拉帮结派。步骤2) 非常关键，因为labeled数据的label是定的，它不能被带跑，所以每次传播完，它都得回归它本来的label。随着labeled数据不断的将自己的label传播出去，最后的类边界会密度区域，而停留在低密度的间隔中。相当于每个不同类别的labeled样本划分了势力范围。

2.3、变身的LP算法

我们知道，我们每次迭代都是计算一个soft label矩阵 $F = [Y_L; Y_U]$ ，但是 Y_L 是已知的，计算它没有什么用，在步骤2) 的时候，还得回来。我们关心的只是 Y_U ，那我们能不能只计算 Y_U 呢？Yes。我们将矩阵 P 做以下划分：

$$P = \begin{bmatrix} P_{LL} & P_{LU} \\ P_{UL} & P_{UU} \end{bmatrix}$$

这时候，我们的算法就一个运算：

$$f_U \leftarrow P_{UU}f_U + P_{UL}Y_L$$

迭代上面这个步骤直到收敛就ok了，是不是很cool。可以看到 f_U 不但取决于labeled数据的标签及其转移概率，还取决于unlabeled当前label和转移概率。因此LP算法能额外运用unlabeled数据的分布特点。

这个算法的收敛性也非常容易证明，具体见参考文献[1]。实际上，它是可以收敛到一个凸解的：

$$f_U = (I - P_{UU})^{-1} P_{UL} Y_L$$

所以我们可以直接这样求解，以获得最终的 Y_U 。但是在实际的应用过程中，由于矩阵求逆需要 $O(n^3)$ 的复杂度，所以如果unlabeled数据非常多，那么 $I - P_{UU}$ 矩阵的求逆将会非常耗时，因此这时候一般选择迭代算法来实现。

三、LP算法的Python实现

Python环境的搭建就不啰嗦了，可以参考前面的博客。需要额外依赖的库是经典的numpy和matplotlib。代码中包含了两种图的方法：RBF和KNN指定。同时，自己生成了两个toy数据库：两条长形形状和两个圈圈的数据。第四部分我们用大点的数据库来做实验，

的可视化验证代码的正确性，再前线。

算法代码：

```
[python]
1.  *****
2.  #*
3.  #* Description: label propagation
4.  #* Author: Zou Xiaoyi (zouxy09@qq.com)
5.  #* Date: 2015-10-15
6.  #* HomePage: http://blog.csdn.net/zouxy09
7.  #*
8.  *****
9.
10. import time
11. import numpy as np
12.
13. # return k neighbors index
14. def navie_knn(dataSet, query, k):
15.     numSamples = dataSet.shape[0]
16.
17.     ## step 1: calculate Euclidean distance
18.     diff = np.tile(query, (numSamples, 1)) - dataSet
19.     squaredDiff = diff ** 2
20.     squaredDist = np.sum(squaredDiff, axis = 1) # sum is performed by row
21.
22.     ## step 2: sort the distance
23.     sortedDistIndices = np.argsort(squaredDist)
24.     if k > len(sortedDistIndices):
25.         k = len(sortedDistIndices)
26.
27.     return sortedDistIndices[0:k]
28.
29.
30. # build a big graph (normalized weight matrix)
31. def buildGraph(MatX, kernel_type, rbf_sigma = None, knn_num_neighbors = None):
32.     num_samples = MatX.shape[0]
33.     affinity_matrix = np.zeros((num_samples, num_samples), np.float32)
34.     if kernel_type == 'rbf':
35.         if rbf_sigma == None:
36.             raise ValueError('You should input a sigma of rbf kernel!')
37.         for i in xrange(num_samples):
38.             row_sum = 0.0
39.             for j in xrange(num_samples):
40.                 diff = MatX[i, :] - MatX[j, :]
41.                 affinity_matrix[i][j] = np.exp(sum(diff**2) / (-2.0 * rbf_sigma**2))
42.                 row_sum += affinity_matrix[i][j]
43.             affinity_matrix[i][:] /= row_sum
44.     elif kernel_type == 'knn':
45.         if knn_num_neighbors == None:
46.             raise ValueError('You should input a k of knn kernel!')
47.         for i in xrange(num_samples):
48.             k_neighbors = navie_knn(MatX, MatX[i, :], knn_num_neighbors)
49.             affinity_matrix[i][k_neighbors] = 1.0 / knn_num_neighbors
50.     else:
51.         raise NameError('Not support kernel type! You can use knn or rbf!')
52.
53.     return affinity_matrix
54.
55.
56. # label propagation
57. def labelPropagation(Mat_Label, Mat_Unlabel, labels, kernel_type = 'rbf', rbf_sigma = 1.5, \
58.     knn_num_neighbors = 10, max_iter = 500, tol = 1e-3):
59.     # initialize
60.     num_label_samples = Mat_Label.shape[0]
61.     num_unlabel_samples = Mat_Unlabel.shape[0]
62.     num_samples = num_label_samples + num_unlabel_samples
63.     labels_list = np.unique(labels)
64.     num_classes = len(labels_list)
65.
66.     MatX = np.vstack((Mat_Label, Mat_Unlabel))
67.     clamp_data_label = np.zeros((num_label_samples, num_classes), np.float32)
68.     for i in xrange(num_label_samples):
69.         clamp_data_label[i][labels[i]] = 1.0
70.
71.     label_function = np.zeros((num_samples, num_classes), np.float32)
72.     label_function[0 : num_label_samples] = clamp_data_label
73.     label_function[num_label_samples : num_samples] = -1
74.
75.     # graph construction
76.     affinity_matrix = buildGraph(MatX, kernel_type, rbf_sigma, knn_num_neighbors)
77.
78.     # start to propagation
79.     iter = 0; pre_label_function = np.zeros((num_samples, num_classes), np.float32)
80.     changed = np.abs(pre_label_function - label_function).sum()
```

```

81. while iter < max_iter and changed > tol:
82.     if iter % 1 == 0:
83.         print "---> Iteration %d/%d, changed: %f" % (iter, max_iter, changed)
84.         pre_label_function = label_function
85.         iter += 1
86.
87.         # propagation
88.         label_function = np.dot(affinity_matrix, label_function)
89.
90.         # clamp
91.         label_function[0 : num_label_samples] = clamp_data_label
92.
93.         # check converge
94.         changed = np.abs(pre_label_function - label_function).sum()
95.
96.     # get terminate label of unlabeled data
97.     unlabeled_data_labels = np.zeros(num_unlabel_samples)
98.     for i in xrange(num_unlabel_samples):
99.         unlabeled_data_labels[i] = np.argmax(label_function[i+num_label_samples])
100.
101.     return unlabeled_data_labels

```

测试代码：

```

[python]
1.  *****
2.  /*
3.  /* Description: label propagation
4.  /* Author: Zou Xiaoyi (zouxy09@qq.com)
5.  /* Date: 2015-10-15
6.  /* HomePage: http://blog.csdn.net/zouxy09
7.  /*
8.  *****
9.
10. import time
11. import math
12. import numpy as np
13. from label_propagation import labelPropagation
14.
15. # show
16. def show(Mat_Label, labels, Mat_Unlabel, unlabeled_data_labels):
17.     import matplotlib.pyplot as plt
18.
19.     for i in range(Mat_Label.shape[0]):
20.         if int(labels[i]) == 0:
21.             plt.plot(Mat_Label[i, 0], Mat_Label[i, 1], 'Dr')
22.         elif int(labels[i]) == 1:
23.             plt.plot(Mat_Label[i, 0], Mat_Label[i, 1], 'Db')
24.         else:
25.             plt.plot(Mat_Label[i, 0], Mat_Label[i, 1], 'Dy')
26.
27.     for i in range(Mat_Unlabel.shape[0]):
28.         if int(unlabeled_data_labels[i]) == 0:
29.             plt.plot(Mat_Unlabel[i, 0], Mat_Unlabel[i, 1], 'or')
30.         elif int(unlabeled_data_labels[i]) == 1:
31.             plt.plot(Mat_Unlabel[i, 0], Mat_Unlabel[i, 1], 'ob')
32.         else:
33.             plt.plot(Mat_Unlabel[i, 0], Mat_Unlabel[i, 1], 'oy')
34.
35.     plt.xlabel('X1'); plt.ylabel('X2')
36.     plt.xlim(0.0, 12.)
37.     plt.ylim(0.0, 12.)
38.     plt.show()
39.
40.
41. def loadCircleData(num_data):
42.     center = np.array([5.0, 5.0])
43.     radiu_inner = 2
44.     radiu_outer = 4
45.     num_inner = num_data / 3
46.     num_outer = num_data - num_inner
47.
48.     data = []
49.     theta = 0.0
50.     for i in range(num_inner):
51.         pho = (theta % 360) * math.pi / 180
52.         tmp = np.zeros(2, np.float32)
53.         tmp[0] = radiu_inner * math.cos(pho) + np.random.rand(1) + center[0]
54.         tmp[1] = radiu_inner * math.sin(pho) + np.random.rand(1) + center[1]
55.         data.append(tmp)
56.         theta += 2
57.
58.     theta = 0.0
59.     for i in range(num_outer):
60.         pho = (theta % 360) * math.pi / 180

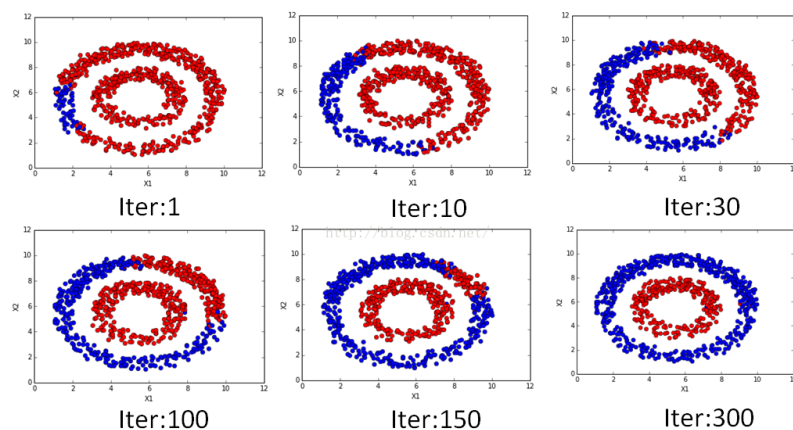
```

```

61.         tmp = np.zeros(2, np.float32)
62.         tmp[0] = radiu_outer * math.cos(pho) + np.random.rand(1) + center[0]
63.         tmp[1] = radiu_outer * math.sin(pho) + np.random.rand(1) + center[1]
64.         data.append(tmp)
65.         theta += 1
66.
67.     Mat_Label = np.zeros((2, 2), np.float32)
68.     Mat_Label[0] = center + np.array([-radiu_inner + 0.5, 0])
69.     Mat_Label[1] = center + np.array([-radiu_outer + 0.5, 0])
70.     labels = [0, 1]
71.     Mat_Unlabel = np.vstack(data)
72.     return Mat_Label, labels, Mat_Unlabel
73.
74.
75. def loadBandData(num_unlabel_samples):
76.     #Mat_Label = np.array([[5.0, 2.], [5.0, 8.0]])
77.     #labels = [0, 1]
78.     #Mat_Unlabel = np.array([[5.1, 2.], [5.0, 8.1]])
79.
80.     Mat_Label = np.array([[5.0, 2.], [5.0, 8.0]])
81.     labels = [0, 1]
82.     num_dim = Mat_Label.shape[1]
83.     Mat_Unlabel = np.zeros((num_unlabel_samples, num_dim), np.float32)
84.     Mat_Unlabel[:num_unlabel_samples/2, :] = (np.random.rand(num_unlabel_samples/2, num_dim) - 0.5) * np.array([3, 1]) + Mat_Label[0]
85.     Mat_Unlabel[num_unlabel_samples/2 : num_unlabel_samples, :] = (np.random.rand(num_unlabel_samples/2, num_dim) - 0.5) * np.array([3, 1])
86.     t_Label[1]
87.     return Mat_Label, labels, Mat_Unlabel
88.
89. # main function
90. if __name__ == "__main__":
91.     num_unlabel_samples = 800
92.     #Mat_Label, labels, Mat_Unlabel = loadBandData(num_unlabel_samples)
93.     Mat_Label, labels, Mat_Unlabel = loadCircleData(num_unlabel_samples)
94.
95.     ## Notice: when use 'rbf' as our kernel, the choice of hyper parameter 'sigma' is very import! It should be
96.     ## chose according to your dataset, specific the distance of two data points. I think it should ensure that
97.     ## each point has about 10 knn or w_i,j is large enough. It also influence the speed of converge. So, may be
98.     ## 'knn' kernel is better!
99.     #unlabel_data_labels = labelPropagation(Mat_Label, Mat_Unlabel, labels, kernel_type = 'rbf', rbf_sigma = 0.2)
100.    unlabel_data_labels = labelPropagation(Mat_Label, Mat_Unlabel, labels, kernel_type = 'knn', knn_num_neighbors = 10, max_iter = 400)
101.    show(Mat_Label, labels, Mat_Unlabel, unlabel_data_labels)
102.

```

该注释的，代码都注释的，有看不明白的，欢迎交流。不同迭代次数时候的结果如下：



是不是很漂亮传播过程？！在数值上也是可以看到随着迭代的进行逐渐收敛的，迭代的数值变化过程如下：

[python]

```

1.  ---> Iteration 0/400, changed: 1602.000000
2.  ---> Iteration 1/400, changed: 6.300182
3.  ---> Iteration 2/400, changed: 5.129996
4.  ---> Iteration 3/400, changed: 4.301994
5.  ---> Iteration 4/400, changed: 3.819295
6.  ---> Iteration 5/400, changed: 3.501743
7.  ---> Iteration 6/400, changed: 3.277122
8.  ---> Iteration 7/400, changed: 3.105952
9.  ---> Iteration 8/400, changed: 2.967030
10. ---> Iteration 9/400, changed: 2.848606
11. ---> Iteration 10/400, changed: 2.743997
12. ---> Iteration 11/400, changed: 2.649270
13. ---> Iteration 12/400, changed: 2.562057
14. ---> Iteration 13/400, changed: 2.480885
15. ---> Iteration 14/400, changed: 2.404774
16. ---> Iteration 15/400, changed: 2.333075
17. ---> Iteration 16/400, changed: 2.265301

```

18. ---> Iteration 17/400, changed: 2.201107
19. ---> Iteration 18/400, changed: 2.140209
20. ---> Iteration 19/400, changed: 2.082354
21. ---> Iteration 20/400, changed: 2.027376
22. ---> Iteration 21/400, changed: 1.975071
23. ---> Iteration 22/400, changed: 1.925286
24. ---> Iteration 23/400, changed: 1.877894
25. ---> Iteration 24/400, changed: 1.832743
26. ---> Iteration 25/400, changed: 1.789721
27. ---> Iteration 26/400, changed: 1.748706
28. ---> Iteration 27/400, changed: 1.709593
29. ---> Iteration 28/400, changed: 1.672284
30. ---> Iteration 29/400, changed: 1.636668
31. ---> Iteration 30/400, changed: 1.602668
32. ---> Iteration 31/400, changed: 1.570200
33. ---> Iteration 32/400, changed: 1.539179
34. ---> Iteration 33/400, changed: 1.509530
35. ---> Iteration 34/400, changed: 1.481182
36. ---> Iteration 35/400, changed: 1.454066
37. ---> Iteration 36/400, changed: 1.428120
38. ---> Iteration 37/400, changed: 1.403283
39. ---> Iteration 38/400, changed: 1.379502
40. ---> Iteration 39/400, changed: 1.356734
41. ---> Iteration 40/400, changed: 1.334906
42. ---> Iteration 41/400, changed: 1.313983
43. ---> Iteration 42/400, changed: 1.293921
44. ---> Iteration 43/400, changed: 1.274681
45. ---> Iteration 44/400, changed: 1.256214
46. ---> Iteration 45/400, changed: 1.238491
47. ---> Iteration 46/400, changed: 1.221474
48. ---> Iteration 47/400, changed: 1.205126
49. ---> Iteration 48/400, changed: 1.189417
50. ---> Iteration 49/400, changed: 1.174316
51. ---> Iteration 50/400, changed: 1.159804
52. ---> Iteration 51/400, changed: 1.145844
53. ---> Iteration 52/400, changed: 1.132414
54. ---> Iteration 53/400, changed: 1.119490
55. ---> Iteration 54/400, changed: 1.107032
56. ---> Iteration 55/400, changed: 1.095054
57. ---> Iteration 56/400, changed: 1.083513
58. ---> Iteration 57/400, changed: 1.072397
59. ---> Iteration 58/400, changed: 1.061671
60. ---> Iteration 59/400, changed: 1.051324
61. ---> Iteration 60/400, changed: 1.041363
62. ---> Iteration 61/400, changed: 1.031742
63. ---> Iteration 62/400, changed: 1.022459
64. ---> Iteration 63/400, changed: 1.013494
65. ---> Iteration 64/400, changed: 1.004836
66. ---> Iteration 65/400, changed: 0.996484
67. ---> Iteration 66/400, changed: 0.988407
68. ---> Iteration 67/400, changed: 0.980592
69. ---> Iteration 68/400, changed: 0.973045
70. ---> Iteration 69/400, changed: 0.965744
71. ---> Iteration 70/400, changed: 0.958682
72. ---> Iteration 71/400, changed: 0.951848
73. ---> Iteration 72/400, changed: 0.945227
74. ---> Iteration 73/400, changed: 0.938820
75. ---> Iteration 74/400, changed: 0.932608
76. ---> Iteration 75/400, changed: 0.926590
77. ---> Iteration 76/400, changed: 0.920765
78. ---> Iteration 77/400, changed: 0.915107
79. ---> Iteration 78/400, changed: 0.909628
80. ---> Iteration 79/400, changed: 0.904309
81. ---> Iteration 80/400, changed: 0.899143
82. ---> Iteration 81/400, changed: 0.894122
83. ---> Iteration 82/400, changed: 0.889259
84. ---> Iteration 83/400, changed: 0.884530
85. ---> Iteration 84/400, changed: 0.879933
86. ---> Iteration 85/400, changed: 0.875464
87. ---> Iteration 86/400, changed: 0.871121
88. ---> Iteration 87/400, changed: 0.866888
89. ---> Iteration 88/400, changed: 0.862773
90. ---> Iteration 89/400, changed: 0.858783
91. ---> Iteration 90/400, changed: 0.854879
92. ---> Iteration 91/400, changed: 0.851084
93. ---> Iteration 92/400, changed: 0.847382
94. ---> Iteration 93/400, changed: 0.843779
95. ---> Iteration 94/400, changed: 0.840274
96. ---> Iteration 95/400, changed: 0.836842
97. ---> Iteration 96/400, changed: 0.833501
98. ---> Iteration 97/400, changed: 0.830240
99. ---> Iteration 98/400, changed: 0.827051
100. ---> Iteration 99/400, changed: 0.823950
101. ---> Iteration 100/400, changed: 0.820906
102. ---> Iteration 101/400, changed: 0.817946
103. ---> Iteration 102/400, changed: 0.815053
104. ---> Iteration 103/400, changed: 0.812217


```

105. ---> Iteration 104/400, changed: 0.809437
106. ---> Iteration 105/400, changed: 0.806724
107. ---> Iteration 106/400, changed: 0.804076
108. ---> Iteration 107/400, changed: 0.801480
109. ---> Iteration 108/400, changed: 0.798937
110. ---> Iteration 109/400, changed: 0.796448
111. ---> Iteration 110/400, changed: 0.794008
112. ---> Iteration 111/400, changed: 0.791612
113. ---> Iteration 112/400, changed: 0.789282
114. ---> Iteration 113/400, changed: 0.786984
115. ---> Iteration 114/400, changed: 0.784728
116. ---> Iteration 115/400, changed: 0.782516
117. ---> Iteration 116/400, changed: 0.780355
118. ---> Iteration 117/400, changed: 0.778216
119. ---> Iteration 118/400, changed: 0.776139
120. ---> Iteration 119/400, changed: 0.774087
121. ---> Iteration 120/400, changed: 0.772072
122. ---> Iteration 121/400, changed: 0.770085
123. ---> Iteration 122/400, changed: 0.768146
124. ---> Iteration 123/400, changed: 0.766232
125. ---> Iteration 124/400, changed: 0.764356
126. ---> Iteration 125/400, changed: 0.762504
127. ---> Iteration 126/400, changed: 0.760685
128. ---> Iteration 127/400, changed: 0.758889
129. ---> Iteration 128/400, changed: 0.757135
130. ---> Iteration 129/400, changed: 0.755406

```

四、LP算法MPI并行实现

这里，我们测试的是LP的变身版本。从公式，我们可以看到，第二项 $P_{UL}Y_L$ 迭代过程并没有发生变化，所以这部分实际上从迭代可以计算好，从而避免重复计算。不过，不管怎样，LP算法都要计算一个 $U \times U$ 的矩阵 P_{UU} 和一个 $U \times C$ 矩阵 F_U 的乘积。当我们的unlabeled非常多，而且类别也很多的时候，计算是很慢的，同时占用的内存量也非常大。另外，构造Graph需要计算两两的相似度，也是 $O(n^2)$ 度，当我们数据的特征维度很大的时候，这个计算量也是非常客观的。所以我们就得考虑并行处理了。而且最好是能放到集群上并行何并行呢？

对算法的并行化，一般分为两种：数据并行和模型并行。

数据并行很好理解，就是将数据划分，每个节点只处理一部分数据，例如我们构造图的时候，计算每个数据的k近邻。例如我们有样本和20个CPU节点，那么就平均分发，让每个CPU节点计算50个样本的k近邻，然后最后再合并大家的结果。可见这个加速比也是可观的。

模型并行一般发生在模型很大，无法放到单机的内存里面的时候。例如庞大的深度神经网络训练的时候，就需要把这个网络切开分别求解梯度，最后有个leader的节点来收集大家的梯度，再反馈给大家去更新。当然了，其中存在更细致和高效的工程处理方法。在LP算法中，也是可以做模型并行的。假如我们的类别数C很大，把类别数切开，让不同的CPU节点处理，实际上就相当于模型并行了。

那为啥不切大矩阵 P_{UU} ，而是切小点的矩阵 F_U ，因为大矩阵 P_{UU} 没法独立分块，并行的一个原则是处理必须是独立的。矩阵 F_U 依所有的U，而把 P_{UU} 切开发到其他节点的时候，每次 F_U 的更新都需要和其他的节点通信，这个通信的代价是很大的（实际上，很多并没法达到线性的加速度的瓶颈是通信！线性加速比是，我增加了n台机器，速度就提升了n倍）。但是对类别C也就是矩阵 F_U 切分，就这个问题，因为他们的计算是独立的。只是决定样本的最终类别的时候，将所有的 F_U 收集回来求max就可以了。

所以，在下面的代码中，是同时包含了数据并行和模型并行的雏形的。另外，还值得一提的是，我们是迭代算法，那决定什么时候算法停止？除了判断收敛外，我们还可以让每迭代几步，就用测试label测试一次结果，看模型的整体训练性能如何。特别是判断训练拟合的时候非常有效。因此，代码中包含了这部分内容。

好了，代码终于来了。大家可以搞点大数据库来测试，如果有MPI集群条件的话就更好了。

下面的代码依赖numpy、scipy（用其稀疏矩阵加速计算）和mpi4py。其中mpi4py需要依赖openmpi和Cpython，可以参考我[之前](#)进行安装。

```

[python]
1.  *****
2.  #*
3.  #* Description: label propagation
4.  #* Author: Zou Xiaoyi (zouxy09@qq.com)
5.  #* Date: 2015-10-15
6.  #* HomePage: http://blog.csdn.net/zouxy09
7.  #*
8.  *****
9.
10. import os, sys, time
11. import numpy as np
12. from scipy.sparse import csr_matrix, lil_matrix, eye
13. import operator
14. import cPickle as pickle
15. import mpi4py.MPI as MPI

```

```

16.
17. #
18. # Global variables for MPI
19. #
20.
21. # instance for invoking MPI related functions
22. comm = MPI.COMM_WORLD
23. # the node rank in the whole community
24. comm_rank = comm.Get_rank()
25. # the size of the whole community, i.e., the total number of working nodes in the MPI cluster
26. comm_size = comm.Get_size()
27.
28. # load mnist dataset
29. def load_MNIST():
30.     import gzip
31.     f = gzip.open("mnist.pkl.gz", "rb")
32.     train, val, test = pickle.load(f)
33.     f.close()
34.
35.     Mat_Label = train[0]
36.     labels = train[1]
37.     Mat_Unlabel = test[0]
38.     groundtruth = test[1]
39.     labels_id = [0, 1, 2, 3, 4, 5, 6, 7, 8, 9]
40.
41.     return Mat_Label, labels, labels_id, Mat_Unlabel, groundtruth
42.
43. # return k neighbors index
44. def navie_knn(dataSet, query, k):
45.     numSamples = dataSet.shape[0]
46.
47.     ## step 1: calculate Euclidean distance
48.     diff = np.tile(query, (numSamples, 1)) - dataSet
49.     squaredDiff = diff ** 2
50.     squaredDist = np.sum(squaredDiff, axis = 1) # sum is performed by row
51.
52.     ## step 2: sort the distance
53.     sortedDistIndices = np.argsort(squaredDist)
54.     if k > len(sortedDistIndices):
55.         k = len(sortedDistIndices)
56.     return sortedDistIndices[0:k]
57.
58.
59. # build a big graph (normalized weight matrix)
60. # sparse U x (U + L) matrix
61. def buildSubGraph(Mat_Label, Mat_Unlabel, knn_num_neighbors):
62.     num_unlabel_samples = Mat_Unlabel.shape[0]
63.     data = []; indices = []; indptr = [0]
64.     Mat_all = np.vstack((Mat_Label, Mat_Unlabel))
65.     values = np.ones(knn_num_neighbors, np.float32) / knn_num_neighbors
66.     for i in xrange(num_unlabel_samples):
67.         k_neighbors = navie_knn(Mat_all, Mat_Unlabel[i, :], knn_num_neighbors)
68.         indptr.append(np.int32(indptr[-1]) + knn_num_neighbors)
69.         indices.extend(k_neighbors)
70.         data.append(values)
71.     return csr_matrix((np.hstack(data), indices, indptr))
72.
73.
74. # build a big graph (normalized weight matrix)
75. # sparse U x (U + L) matrix
76. def buildSubGraph_MPI(Mat_Label, Mat_Unlabel, knn_num_neighbors):
77.     num_unlabel_samples = Mat_Unlabel.shape[0]
78.     local_data = []; local_indices = []; local_indptr = [0]
79.     Mat_all = np.vstack((Mat_Label, Mat_Unlabel))
80.     values = np.ones(knn_num_neighbors, np.float32) / knn_num_neighbors
81.     sample_offset = np.linspace(0, num_unlabel_samples, comm_size + 1).astype('int')
82.     for i in range(sample_offset[comm_rank], sample_offset[comm_rank+1]):
83.         k_neighbors = navie_knn(Mat_all, Mat_Unlabel[i, :], knn_num_neighbors)
84.         local_indptr.append(np.int32(local_indptr[-1]) + knn_num_neighbors)
85.         local_indices.extend(k_neighbors)
86.         local_data.append(values)
87.     data = np.hstack(comm.allgather(local_data))
88.     indices = np.hstack(comm.allgather(local_indices))
89.     indptr_tmp = comm.allgather(local_indptr)
90.     indptr = []
91.     for i in range(len(indptr_tmp)):
92.         if i == 0:
93.             indptr.extend(indptr_tmp[i])
94.         else:
95.             last_indptr = indptr[-1]
96.             del(indptr[-1])
97.             indptr.extend(indptr_tmp[i] + last_indptr)
98.     return csr_matrix((np.hstack(data), indices, indptr), dtype = np.float32)
99.
100.
101. # label propagation
102. def run_label_propagation_sparse(knn_num_neighbors = 20, max_iter = 100, tol = 1e-4, test_per_iter = 1):

```



```

103. # load data and graph
104. print "Processor %d/%d loading graph file..." % (comm_rank, comm_size)
105. #Mat_Label, labels, Mat_Unlabel, groundtruth = loadFourBandData()
106. Mat_Label, labels, labels_id, Mat_Unlabel, unlabel_data_id = load_MNIST()
107. if comm_size > len(labels_id):
108.     raise ValueError("Sorry, the processors must be less than the number of classes")
109. #affinity_matrix = buildSubGraph(Mat_Label, Mat_Unlabel, knn_num_neighbors)
110. affinity_matrix = buildSubGraph_MPI(Mat_Label, Mat_Unlabel, knn_num_neighbors)
111.
112. # get some parameters
113. num_classes = len(labels_id)
114. num_label_samples = len(labels)
115. num_unlabel_samples = Mat_Unlabel.shape[0]
116.
117. affinity_matrix_UL = affinity_matrix[:, 0:num_label_samples]
118. affinity_matrix_UU = affinity_matrix[:, num_label_samples:num_label_samples+num_unlabel_samples]
119.
120. if comm_rank == 0:
121.     print "Have %d labeled images, %d unlabeled images and %d classes" % (num_label_samples, num_unlabel_samples, num_classes)
122.
123. # divide label_function_U and label_function_L to all processors
124. class_offset = np.linspace(0, num_classes, comm_size + 1).astype('int')
125.
126. # initialize local label_function_U
127. local_start_class = class_offset[comm_rank]
128. local_num_classes = class_offset[comm_rank+1] - local_start_class
129. local_label_function_U = eye(num_unlabel_samples, local_num_classes, 0, np.float32, format='csr')
130.
131. # initialize local label_function_L
132. local_label_function_L = lil_matrix((num_label_samples, local_num_classes), dtype = np.float32)
133. for i in xrange(num_label_samples):
134.     class_off = int(labels[i]) - local_start_class
135.     if class_off >= 0 and class_off < local_num_classes:
136.         local_label_function_L[i, class_off] = 1.0
137. local_label_function_L = local_label_function_L.tocsr()
138. local_label_info = affinity_matrix_UL.dot(local_label_function_L)
139. print "Processor %d/%d has to process %d classes..." % (comm_rank, comm_size, local_label_function_L.shape[1])
140.
141. # start to propagation
142. iter = 1; changed = 100.0;
143. evaluation(num_unlabel_samples, local_start_class, local_label_function_U, unlabel_data_id, labels_id)
144. while True:
145.     pre_label_function = local_label_function_U.copy()
146.
147.     # propagation
148.     local_label_function_U = affinity_matrix_UU.dot(local_label_function_U) + local_label_info
149.
150.     # check converge
151.     local_changed = abs(pre_label_function - local_label_function_U).sum()
152.     changed = comm.reduce(local_changed, root = 0, op = MPI.SUM)
153.     status = 'RUN'
154.     test = False
155.     if comm_rank == 0:
156.         if iter % 1 == 0:
157.             norm_changed = changed / (num_unlabel_samples * num_classes)
158.             print "---> Iteration %d/%d, changed: %f" % (iter, max_iter, norm_changed)
159.             if iter >= max_iter or changed < tol:
160.                 status = 'STOP'
161.                 print "***** Iteration over! *****"
162.             if iter % test_per_iter == 0:
163.                 test = True
164.                 iter += 1
165.             test = comm.bcast(test if comm_rank == 0 else None, root = 0)
166.             status = comm.bcast(status if comm_rank == 0 else None, root = 0)
167.             if status == 'STOP':
168.                 break
169.             if test == True:
170.                 evaluation(num_unlabel_samples, local_start_class, local_label_function_U, unlabel_data_id, labels_id)
171. evaluation(num_unlabel_samples, local_start_class, local_label_function_U, unlabel_data_id, labels_id)
172.
173.
174. def evaluation(num_unlabel_samples, local_start_class, local_label_function_U, unlabel_data_id, labels_id):
175.     # get local label with max score
176.     if comm_rank == 0:
177.         print "Start to combine local result..."
178.     local_max_score = np.zeros((num_unlabel_samples, 1), np.float32)
179.     local_max_label = np.zeros((num_unlabel_samples, 1), np.int32)
180.     for i in xrange(num_unlabel_samples):
181.         local_max_label[i, 0] = np.argmax(local_label_function_U.getrow(i).todense())
182.         local_max_score[i, 0] = local_label_function_U[i, local_max_label[i, 0]]
183.         local_max_label[i, 0] += local_start_class
184.
185.     # gather the results from all the processors
186.     if comm_rank == 0:
187.         print "Start to gather results from all processors"
188.     all_max_label = np.hstack(comm.allgather(local_max_label))
189.     all_max_score = np.hstack(comm.allgather(local_max_score))

```

```
190.
191.     # get terminate label of unlabeled data
192.     if comm_rank == 0:
193.         print "Start to analysis the results..."
194.         right_predict_count = 0
195.         for i in xrange(num_unlabel_samples):
196.             if i % 1000 == 0:
197.                 print "****", all_max_score[i]
198.                 max_idx = np.argmax(all_max_score[i])
199.                 max_label = all_max_label[i, max_idx]
200.                 if int(unlabel_data_id[i]) == int(labels_id[max_label]):
201.                     right_predict_count += 1
202.             accuracy = float(right_predict_count) * 100.0 / num_unlabel_samples
203.             print "Have %d samples, accuracy: %.3f%%!" % (num_unlabel_samples, accuracy)
204.
205.
206. if __name__ == '__main__':
207.     run_label_propagation_sparse(knn_num_neighbors = 20, max_iter = 30)
```

五、参考资料

[1][Semi-Supervised Learning with Graphs.pdf](#)

- [上一篇](#) 图像卷积与滤波的一些知识点